

Reinforcement learning in the domain of games



Učenie posilňovaním v doméne hier

Juraj Povinec

Školiteľ: doc. Ing. Peter Lacko, PhD


Prostredie

- Atari 2600 Space Invaders
- Štandardný Atari benchmark
- ALE/Gymnasium
- `env.step(action)`
- Predspracovanie pozorovaní




Agent Algoritmus

- Discrete Soft Actor-Critic
- Off-policy algoritmus
- Actor-Critic metóda
- Maximalizuje entropiu politiky spolu s kumulatívnou odmenou
- Implementácia z knižnice CleanRL



Agent

Architektúra neurónových sietí



Agent

Rozšírenia

- Paralelizácia prostredí
- Stored Embeddings for Efficient Reinforcement Learning (SEER)
- Soft Actor-Critic with Autoencoder (SAC+AE)
- Stable Discrete Soft Actor-Critic (SD-SAC)
- Munchausen Reinforcement Learning

Dosiahnuté výsledky

Paralelizácia prostredí

- 2,000,000 krokov
- Paralelizácia 1, 4, 8 prostredí
- Zrýchlenie až o 36%
- Pri 4 prostrediach bez straty výkonu agenta

Number of environments	Wall time [minutes]	Steps per second	Mean score
1	214	155	1,039.01
4	143 (−33%)	230 (+48%)	1,021.39 (−2%)
8	137 (−36%)	240 (+55%)	954.75 (−8%)

Dosiahnuté výsledky

Stored Embeddings for Efficient Reinforcement learning

- 5,000,000 krokov
- Test iba zmrazovania enkóderov
- Test s hlbšou neurónovou sieťou
- Test so skorším zmrazením

Agent	Wall time [minutes]	Steps per second	Mean score
SAC-D	369	225	1,541.30
SEER	326 (−12%)	257 (+14%)	1,103.10 (−28%)
Freezing	333 (−10%)	248 (+10%)	998.90 (−35%)
3L MLP Freezing	347 (−6%)	237 (+5%)	1,221.81 (−21%)
3L MLP Freezing 100k	terminated	N/A	N/A

Dosiahnuté výsledky

Soft Actor-Critic with Autoencoder

- 1,000,000 krokov
- Výrazne pomalší a horší
- Príliš komplexný autoenkóder
- Hyperparametre

Agent	Wall time [minutes]	Steps per second	Mean score
SAC-D	69	155	640.69
SAC+AE	288 (+417%)	56 (−64%)	346.19 (−46%)

Dosiahnuté výsledky

Stable Discrete Soft Actor-Critic

- 5,000,000 krokov
- Zabránilo rýchlemu poklesu entropie politiky
- Mitigovalo podhodnocovanie ohodnotenia akcií
- Test s rôznymi nastaveniami parametrov
- Nepodarilo sa nájsť nastavenie, ktoré by zlepšilo priemerné skóre

Agent	Mean score
SAC-D	1,541.30
SD-SAC	1,285.62 (−17%)
SD-SAC $c = 0.75$	1,123.72 (−27%)
SD-SAC $c = 0.25$	1,155.16 (−25%)
SD-SAC $\beta = 0.75$	1,202.42 (−22%)
SD-SAC $\beta = 0.25$	1,234.31 (−20%)

Dosiahnuté výsledky


Munchausen Reinforcement Learning

- 5,000,000 krokov
- Príliš veľký vplyv na signál odmeny
- Testy s rôznymi hodnotami parametrov
- O 5% vyššie priemerné skóre agenta

Agent	Mean score
SAC-D	1,541.30
SAC MRL	1,188.08 (−23%)
MRL $l_0 = -0.75$	1,145.64 (−26%)
MRL $l_0 = -0.50$	1,237.44 (−20%)
MRL $l_0 = -0.25$	1,117.15 (−28%)
MRL $\tau = 0.70$	1,406.12 (−9%)
MRL $\tau = 0.50$	1,464.12 (−5%)
MRL $\tau = 0.30$	1,439.52 (−7%)
MRL $\tau = 0.50; l_0 = -0.50$	1,614.08 (+5%)

Zhrnutie

- Pracoval som s algoritmom Discrete Soft Actor-Critic
- Implementoval a otestoval som modifikácie na zrýchlenie algoritmu: paralelizácia prostredí, SEER, SAC+AE
- Úspešne som zrýchlil algoritmus o 48% (skrátil trvanie tréningu o 33%)
- Implementoval a otestoval som modifikácie na zlepšenie výkonu algoritmu: SD-SAC, Munchausen RL
- Podarilo sa mi vylepšiť priemerné skóre, ktoré dosahoval algoritmus o 5%



Ďakujem za pozornosť

Poznámky k práci

1. Space Invaders je pomerne jednoduchá hra, kde by sa dal umelý hráč riešiť klasickým algoritmom (vyhýbanie sa strelám a v rámci toho strelba na najbližší cieľ, strely a ciele je možné identifikovať veľmi jednoducho a v pôvodnom rozlíšení). Nenapadlo autora porovnať kvalitu takéhoto riešenia s výsledkom RL? Ak aj nie, ako si autor myslí, že by to dopadlo?
2. Hra Space Invaders je pre ľudí ťažká, lebo je náročná na reakčný čas. Má umelý hráč, ktorý má reakčný čas rýchlejší, rovnaké podmienky pri hraní tejto hry, ale je mu dovolené spraviť tolko krokov za sekundu koľko stihne?

Otázky

1. Porovnajete grafické užívateľské rozhrania ATARI hier s modernými užívateľskými rozhraniami z pohľadu vývojára softvéru.
2. Algoritmus spätného šírenia v kontexte trénovania neurónovej siete.
3. Efektívne reprezentácie dátovej štruktúry graf. Využitie problému Union-find pri hľadaní kostry grafu.
4. Spôsoby prehľadávania stavového priestoru, do hĺbky a do šírky, Dijkstrov algoritmus. Porovnanie implementácií v rôznych jazykoch.



Agent

Implementácia

- SAC-Discrete od CleanRL
- Aktualizované dependencies
- Refactoring
- Doplnené rozšírenia


Tréningové grafy

Paralelizácia prostredí





Tréningové grafy

Stored Embeddings for Efficient Reinforcement learning



Tréningové grafy

Stored Embeddings for Efficient Reinforcement learning





Tréningové grafy

Soft Actor-Critic with Autoencoder





Tréningové grafy

Stable Discrete Soft Actor-Critic



Tréningové grafy

Stable Discrete Soft Actor-Critic



Tréningové grafy

Munchausen Reinforcement Learning

